

World Model + Navigation 前沿研究报告

核心结论

世界模型导航的关键，不只是预测未来画面，而是让预测真正帮助动作选择。现有工作分别改善表示、动力学、目标度量、动作搜索、记忆和反馈，但没有一种架构已经同时解决未知地图、长程规划、部分观测与可靠部署。

围绕 LeWorldModel (LeWM)，优先研究“可达性度量 + 受约束的长程规划 + 历史记忆”比直接扩大全模型更有针对性。TRM、RC-aux 与 Hi-LeWM 已直接切入 LeWM 的规划弱点；HWM 提供未知布局的分层导航证据；NavMorph、SC2-WM 则说明记忆与反馈对第一人称导航的重要性。

[7][9][11][12][14][15]

范围与证据口径

覆盖 22 项代表性工作，以 2025-2026 年为主，并纳入 2024 年首次公开的基础论文；资料截止 2026 年 9 月 10 日。重点是地面机器人图像目标导航、视觉语言导航和可迁移的潜空间规划，不以自动驾驶或无人机为主体。本文是有针对性的研究综述，不是穷尽式文献目录。

数值均为相应论文或官方项目所报告，不是本报告重新运行的结果。“不足”中标为分析的内容，是根据任务设置推导的研究风险，不应误认为作者已完成相关实验。未确认正式发表的工作按预印本处理；Workshop 不等同于主会。

阅读路线

关心的问题	建议优先阅读
LeWM 为什么可能预测准确却到不了目标？	LeWM → TRM → RC-aux
如何走得更远、跨过障碍和未知布局？	PLDM → HWM → Hi-LeWM
第一人称导航如何处理历史与反馈？	NavMorph → SC2-WM → UniWM
怎样减少搜索成本并保持动作有效？	NWM → PiJEPa → CompACT
如何增加语言、物体目标和空间知识？	UNeMo → WMNav → GeniNav

7. NavMorph: A Self-Evolving World Model for Vision-and-Language Navigation in Continuous Environments (2025, ICCV)。

9. SC2-WM: A Self-Correcting World Model with Closed-Loop Feedback for Vision-and-Language Navigation in Continuous Environments (2026, ICML)。

11. World Model Control by Trajectory Reachability Metrics (2026, arXiv v2)。

12. Predictive but Not Plannable: RC-aux for Latent World Models (2026, arXiv v1)。

14. Hierarchical Planning with Latent World Models (2026, arXiv v2)。

15. Mind the Gap: Promises and Pitfalls of Hierarchical Planning in LeWorldModel (2026, arXiv v2)。

1 任务与评价：先确定在测什么

三类目标不是同一个问题

图像目标导航（Image-goal Navigation）给定目标位置的图像，要求走到相应地点。视觉语言导航（VLN）要求执行自然语言路线指令。物体目标导航（ObjectNav）要求寻找指定类别的物体，往往还涉及对未见区域的探索。三者需要的语义、定位、记忆和探索能力不同，不能仅凭一个成功率互相排名。

四类证据需要分开

证据类型	能够说明什么	不能直接推出什么
离线预测 / 轨迹拟合	对已有数据预测准确；动作与视觉对齐	执行动作后仍能到达目标
模型内部递归生成	长序列想象具有一定一致性	预测错误会被环境反馈纠正
交互式仿真闭环	执行、观测、重规划形成反馈	已解决真实传感器及控制误差
真实机器人闭环	特定平台与场景上的部署可行性	大规模可靠性或模型独立避障能力

指标解释

SR 是任务成功率。SPL 同时考虑成功和路径长度，常写为：对每个回合计算“成功标记 $\times$ 最短路径长 / $\max(\text{实际路径长}, \text{最短路径长})$ ”后取平均。必须同时报告两者：成功率更高但绕路更严重，并不意味着导航全面更好。

ATE / RPE 衡量轨迹或相对位姿误差，数值越小越好；但一个避开障碍的有效新路线，也可能偏离数据中的参考轨迹。LPIPS、PSNR、FID / FVD 衡量预测图像或视频质量，不直接保证可达性、安全性和任务完成。^[4]

最容易产生误解的比较

必须对齐地图划分、目标距离、成功半径、相机视野、RGB / 深度输入、动作步长与规划预算。

RAE-NWM 使用 1 米成功阈值，而 ReL-NWM 的 Gibson 设置使用 2 米；两篇成功率不能直接放在同一个排行榜。^{[5][6]}

4. Navigation World Models (2025, CVPR)。

5. RAE-NWM: Navigation World Model in Dense Visual Representation Space (2026, arXiv v2)。

6. Efficient Image-Goal Navigation with Representative Latent World Model (2025, arXiv v2)。

2 LeWM: 低成本 JEPA 世界模型的起点

LeWorldModel • 2026 预印本, 采用 v3 • 证据: 像素控制基准; 包含 TwoRoom

研究目的

在不依赖大型预训练视觉编码器的前提下, 从像素和动作共同学习紧凑表示与动力学, 使世界模型能够以较小规模训练并用于目标条件规划。它主要解决训练稳定性与计算成本, 并非专为第一人称导航设计。

方法与框架

图像经小型 ViT 编码并投影为潜变量; 动作条件 Transformer 预测后续潜变量。训练同时最小化预测误差, 并用 SIGReg 约束表示分布以防坍塌; 不依赖 EMA 目标网络或 stop-gradient。规划时用 CEM 搜索动作序列, 以预测终点到目标图像表示的平方距离评分, 再执行并重规划。^[1]

实验效果与证据边界

约 1500 万参数, 论文报告单 GPU 数小时级训练, 并在特定对照下获得最高约 48 倍规划加速。其 TwoRoom 结果弱于 PLDM 和 DINO-WM; 因此“小而稳定”与“导航最强”是两回事。作者提出低内在维度任务与高维高斯正则的匹配问题, 但这仍是解释性假设。^[1]

不足与迁移判断

分析: 目标特征距离未必反映隔墙绕行距离; 短视规划可能倾向看起来接近目标的错误方向。俯视可见地图的 TwoRoom 也不能替代第一人称未知地图导航。紧凑表示若丢失门洞或朝向, 后续规划器无法凭空补回这些信息。

对 LeWM 的启示: 把它作为可控制、可诊断的底座, 先分清“表示缺信息”“动力学不准确”“目标代价错误”和“搜索找不到解”。不要只用训练损失下降来证明导航能力提高。

1. LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels (2026, arXiv v3)。

3 PLDM: 无奖励离线数据中的潜空间规划

NeurIPS 2025 • 证据: 交互式导航与控制; 含数据覆盖诊断

研究目的

比较从同一批无奖励离线轨迹出发, 直接学习目标策略与学习动力学再规划的差异。研究重点不仅是平均分, 还包括数据质量、规模与任务变化下的能力边界。

方法与框架

编码器与动作条件预测器通过多步潜变量预测学习; 用 VICReg 类正则和逆动力学辅助防止退化。可训练预测器集合, 以预测分歧作为规划不确定性惩罚。测试时通过 MPPI 优化目标代价, 并滚动执行; 改变代价可以切换目标行为, 不必重新训练策略。^[2]

实验效果与证据边界

论文比较 6 类方法、23 个数据集。在 TwoRoom 的高质量数据设置中, PLDM 成功率为 $97.8 \pm 0.7\%$; 移除穿门轨迹后降至 $34.4 \pm 2.7\%$, 而该设置下 GCIQL、HILP 仍接近 100%。这一负面结果很重要: 学到局部动力学, 不代表一定能组合出数据未覆盖的关键通路。^[2]

不足与迁移判断

论文结果显示数据覆盖缺口是实际限制, 而非仅需更多计算即可解决。分析: 预测器集成也可能在同一盲区一致犯错; 分歧小不等于可安全通过。还需计入在线规划成本, 不能只比较训练时是否使用奖励。

对 LeWM 的启示: 保留 PLDM 作为从零学习表示的关键基线; 设计“有 / 无穿门数据”“相同帧数的单 / 多地图数据”对照。逆动力学与多步训练值得迁移, 但应单独消融。

2. Learning from Reward-Free Offline Data: A Case for Planning with Latent Dynamics Models (2025, NeurIPS; arXiv v4)。

4 DINO-WM: 用预训练空间特征做规划

ICML 2025 • 证据: Maze / Wall 等控制基准; 非语言导航系统

研究目的

探索预训练视觉模型的空间特征能否直接支撑世界模型, 从而省去像素重建与端到端视觉表示训练, 并把一个动力学模型用于不同图像目标。

方法与框架

冻结 DINOv2, 将图像表示为保留空间布局的 patch tokens; 训练动作条件的时空预测器预测后续特征。测试时在特征空间滚动预测并搜索到达目标的动作, 不必逐步解码出图像。所谓 zero-shot planning 指目标规划的使用方式, 不是对环境动力学完全不训练。^[3]

实验效果与证据边界

主表中 Maze、Wall、Reach、PushT 的成功率分别为 98%、96%、92%、90%。但同表 DreamerV3 在 Maze 和 Wall 均为 100%, 所以不能概括为“所有导航任务都优于 Dreamer”。其价值主要是验证预训练稠密表示能有效服务控制。^[3]

不足与迁移判断

分析: 冻结视觉基础模型隐含了额外预训练资源; 直接与 LeWM 比较参数量或本地训练时间并不公平。稠密 token 增加每次规划的计算量, 而且视觉特征距离仍不天然等于拓扑距离。

对 LeWM 的启示: 将其作为“更强视觉表示”的参照。若冻结 DINO 特征显著修复未知场景, 而只改 LeWM 目标头无效, 才更支持改造表示而不是继续打磨规划器。

3. DINO-WM: World Models on Pre-trained Visual Features Enable Zero-shot Planning (2025, ICML)。

5 NWM：通过想象未来评价导航动作

Navigation World Models • CVPR 2025 • 核心量化证据：离线短轨迹规划

研究目的

从多种机器人与人类第一人称视频中学习可控未来，让规划器比较不同动作的后果，并允许在测试时加入动作限制，而不是只能执行固定策略。

方法与框架

在 VAE 潜空间中使用 Conditional Diffusion Transformer (CDiT)，以历史图像、相对移动 / 转角和时间间隔为条件预测未来。动作选择可以独立使用 CEM，也可以对 NoMaD 提议的多条轨迹进行模拟和重排序。^[4]

实验效果与证据边界

RECON 的 2 秒轨迹评估中，NoMaD 的 ATE / RPE 为 1.93 / 0.52；NWM 独立规划为 1.13 / 0.35；NWM 重排 32 条 NoMaD 候选为 1.78 / 0.48。这支持未来模拟对动作选择有用，但不是未知建筑里长程闭环导航成功率的直接证据。^[4]

不足与迁移判断

论文的未知环境实验主要验证未来视觉预测。分析：扩散采样乘上候选数、规划轮次和预测长度，在线成本很高；若轨迹外推错误，重排序可能选中“想象中很好”的动作。视觉相似终点也可能位于障碍另一侧。

对 LeWM 的启示：最容易借鉴的是“候选生成与候选评价解耦”。先用检索或轻量策略产生有效动作，再让 LeWM 排序；必须与不使用动力学的候选直接执行对照，才能确认世界模型真正有贡献。

4. Navigation World Models (2025, CVPR)。

6 RAE-NWM：在稠密语义表示中生成未来

2026 预印本 v2；作者仓库标注 ECCV 2026 暂定接收 • 证据：Habitat 闭环

研究目的

缓解像素重建导向的压缩表示在长程预测中的结构漂移，让世界模型更多保留空间结构，并直接用这些表示进行导航规划。

方法与框架

冻结 DINOv2 及对应 RAE 解码器，在稠密视觉 token 空间使用流匹配预测状态转移；以 CDiT 与 DDT head 处理高维表示，用可学习门控融合运动与时间条件。CEM 根据未来特征和目标特征的距离选择动作。^[5]

实验效果与证据边界

在论文 Habitat / Matterport3D 图像目标闭环中，平均路径约 8 米，停止在目标 1 米内计为成功。RAE-NWM 的 SR / SPL 为 78.95% / 63.58%，同表 One-Step WM 为 72.67% / 69.10%：它更常到达，却不是路径效率最好。RECON 短轨迹 ATE 1.36 也弱于 NWM 的 1.13。^[5]

不足与迁移判断

作者承认纹理细节与结构稳定性之间的权衡，以及尚未完全等规模训练对照。分析：不能把提升全部归因于表示；动力学目标、架构与容量也变化了。迭代稠密空间预测仍有推理成本。

对 LeWM 的启示：可先研究小规模空间 token 或空间辅助约束，而不是直接迁移整套生成模型。只有在等计算预算下同时检查 SR、SPL 和时延，才能判断更丰富的表示是否值得。

5. RAE-NWM: Navigation World Model in Dense Visual Representation Space (2026, arXiv v2)。

7 ReL-NWM：避免像素解码的轻量导航

预印本：采用 arXiv:2511.11011 当前 HTML 的 ReL-NWM 版本 • 证据：仿真与实机

研究目的

减少世界模型导航中反复生成、解码图像的开销，保留足以控制的结构与语义表示，使潜空间规划更接近可部署的计算预算。

方法与框架

冻结 DINOv3，结合动作 FiLM 调制与时空交叉注意力预测未来特征；在预测 token 与目标 token 的余弦距离上使用 CEM。实机中它是高层路点规划器，下层自主控制系统负责平滑运动和实时避障。^[6]

实验效果与证据边界

Gibson / Habitat-Sim 使用 2 米成功阈值：ReL-NWM 的 SR / SPL 为 60% / 48.5%，LS-NWM 为 55% / 30.9%；每步规划时间分别为 1.49 秒与 5.21 秒，均限于论文配置。论文另在 Unitree G1 上展示约 1 Hz 路点规划。^[6]

不足与迁移判断

分析：实机避障能力不能全部归因于世界模型，因为系统存在独立低层避障栈；室内走廊展示也不代表复杂未知建筑的普遍可靠性。同一 arXiv 编号早期索引使用 LS-NWM 标题，阅读或复现必须固定版本，不能混用其结果。

对 LeWM 的启示：学习直接在控制相关特征中评分及显式动作调制；对导航能力评估则必须区分高层“朝哪里走”与低层“能否安全执行”，避免外部控制器掩盖世界模型缺陷。

6. Efficient Image-Goal Navigation with Representative Latent World Model (2025, arXiv v2)。

8 NavMorph: 记忆与前瞻结合的 VLN

ICCV 2025 • 证据: R2R-CE / RxR-CE 连续环境闭环

研究目的

让导航器不仅根据当前视野反应，还能利用历史经验和预测的未来状态理解指令，从而减轻未见环境中的局部决策与误差累积。

方法与框架

世界感知导航器使用递归潜状态整合观察与历史，前瞻动作模块预测未来视觉特征辅助决策。Contextual Evolution Memory 保存并更新上下文经验，服务后续预测和行为。这里的 CEM 指记忆模块，不是规划中的 Cross-Entropy Method。^[7]

实验效果与证据边界

采用同为单目输入的 R2R-CE 对照：作者重现的 VLN-3DFF 在 val-unseen 上 SR / SPL 为 43.8 / 29.4，NavMorph 为 47.9 / 33.2；test-unseen 为 45.7 / 30.2。改善存在，但仍有大量未成功回合。不能与全景设置结果直接混排。^[7]

不足与迁移判断

分析：增益属于完整系统，涉及语言、视觉 / 深度、历史和策略，不能全算作“动力学预测更好”。记忆在线更新不等同于已经证明通过梯度适配解决 OOD；不相关历史还可能引入干扰。

对 LeWM 的启示：当任务改为第一人称或部分可见地图时，比较单帧、固定多帧、递归记忆与检索记忆。应专门加入视觉相似走廊、回访与绕行任务，证明记忆保存了任务所需的空间信息。

7. NavMorph: A Self-Evolving World Model for Vision-and-Language Navigation in Continuous Environments (2025, ICCV)。

9 UNeMo: 把下一步世界想象用于语言导航

AAAI 2026 • 证据: R2R / REVERIE; 主要是离散拓扑 VLN

研究目的

补足大语言模型导航器只能看到已观测局部信息的问题，在动作确定前推测下一节点可能看到的内容，提高语言、空间状态与动作的协同。

方法与框架

系统先给出粗略导航选择，再用条件变分模型结合语言和邻近部分观测，生成目标节点的未来视觉特征，最后利用这些特征细化导航决策。关键是把世界预测与导航推理耦合，而非孤立训练一个好看的视频生成器。^[8]

实验效果与证据边界

相同 Flan-T5-1.5B 规模下，R2R val-unseen 的 NavGPT-2 基线 SR / SPL 为 70.0 / 59.0，UNeMo 为 72.1 / 61.1；test-unseen 为 72.5 / 61.3，对照为 71.0 / 60.0。这是相对稳健但幅度有限的提升。^[8]

不足与迁移判断

分析：离散拓扑节点导航与连续运动控制的动作难度不同；候选节点本身已经提供了可行动作结构。未来视觉特征也可能只是强化语言先验，而非准确模拟可达状态，因此需要检查预测错误时策略如何响应。

对 LeWM 的启示：可把“语言约束的子目标选择”作为上层模块，保留 LeWM 处理局部动作动力学。应先固定同一组候选节点，比较有无预测特征，避免拓扑图本身带来的收益被算到世界模型上。

8. UNeMo: Collaborative Visual-Language Reasoning and Navigation via a Multimodal World Model (2026, AAAI; arXiv v2)。

10 SC2-WM：前瞻修正与选择性测试时适配

ICML 2026 • 证据：R2R-CE / RxR-CE 连续环境闭环

研究目的

针对未见环境中“世界模型固定、策略被错误预测带偏”的问题，让模型预测反馈到当前决策，并在必要时适配世界模型。

方法与框架

先产生临时动作，预测下一潜状态，以预测未来与当前状态的差异来修正决策表示；再通过记忆与修正策略输出动作。用修正前后动作分布的 KL 差异及置信条件触发测试时重建学习。这里的前瞻差异不是“预测与真实下一观测”的同义词。^[9]

实验效果与证据边界

单目 R2R-CE val-unseen: SC2-WM 的 SR / SPL 为 50.9 / 37.2，而同表 NavMorph 为 47.9 / 33.2；test-unseen 为 47.0 / 32.1，对照为 45.7 / 30.2。说明完整反馈方案有效，但对照差值不等于测试时更新单独造成的提升。^[9]

不足与迁移判断

分析：内部预测反馈仍可能自洽但错误；测试时梯度更新也有噪声放大与遗忘风险。验证时必须声明每回合是否重置权重、是否跨回合保留记忆，以及适配是否使用了不应可见的测试信息。

对 LeWM 的启示：优先做可回退的小型反馈模块：用动作后真实观测检查预测可信度，再决定缩短规划视野或重规划。是否更新参数应后置，并与只更新记忆、只调整规划预算分别比较。

9. SC2-WM: A Self-Correcting World Model with Closed-Loop Feedback for Vision-and-Language Navigation in Continuous Environments (2026, ICML)。

11 WMNav: 为寻找物体建立语义探索记忆

IROS 2025 Oral • 证据: HM3D / MP3D ObjectNav 仿真闭环

研究目的

面对只知道物体类别、却不知道目标在哪的任务，利用视觉语言模型推测更值得探索的方向，并避免在已经搜索过的区域反复打转。

方法与框架

VLM 为各方向预测找到目标的“好奇价值”，通过深度与位姿投影为持续更新的 Curiosity Value Map。结合子任务分解、观测反馈和两阶段动作候选生成，先探索再精确接近目标。其“世界模型”主要是语义状态与探索价值记忆，不是 LeWM 式逐动作潜动力学。^[10]

实验效果与证据边界

论文表 I 中，HM3D 的 SR / SPL 为 58.1% / 31.2%，MP3D 为 45.4% / 17.2%。这些是物体目标任务的结果，不可与图像目标导航成功率比较。系统利用预训练 VLM；training-free 不代表没有预训练数据或推理开销。^[10]

不足与迁移判断

分析：语义常识可能把“床通常在卧室”错误地当成实际可见事实。全景观察、深度 / 位姿与多次模型调用也会影响成本和公平性。价值地图需要处理错误判定、回访和动态环境，而非永久相信一次低置信观察。

对 LeWM 的启示：将语义探索记忆放在上层，为 LeWM 指定局部子目标。评估时可改变物体的典型摆放位置，检查系统是在更新环境知识，还是只遵循数据集中的房间共现偏差。

10. WMNav: Integrating Vision-Language Models into World Models for Object Goal Navigation (2025, IROS)。

12 TRM：修复“视觉接近”与“能够到达”的错位

2026 预印本 v2 • 与 LeWM 直接相关 • 证据：受控 TwoRoom 及候选排序诊断

研究目的

检验导航失败是否主要来自终点评分，而不是世界模型完全不懂运动。隔墙两点可能视觉上接近，但需要很长绕行；潜变量欧氏距离对此未必可靠。

方法与框架

冻结编码器和动力学，用轨迹中的时间间隔学习状态对的可达性 / 距离头，替换或结合原有终点代价。通过固定候选、打乱监督标签、排除评估轨迹以及改变时间跨度，分离评分函数与搜索的贡献。^[11]

实验效果与证据边界

高距离 TwoRoom 评估中，原始 LeWM 潜变量 MSE 成功率为 $7.0 \pm 8.2\%$ ，排除评估起终点所在轨迹的 TRM 为 $96.7 \pm 2.1\%$ ，均为三个种子的均值与标准差。打乱时间标签的头为 0%。这些结果限定在论文的任务与预算，不能与其他 TwoRoom 结果直接合并。^[11]

不足与迁移判断

分析：轨迹时间差是行为策略的行走时间，不是最短可达距离。排除同一轨迹并不等于地图 OOD。论文 TopoNav 诊断使用精确动力学与特定候选构造，不能据此宣称学到未知地图的普适导航。

对 LeWM 的启示：这是低成本、强可解释性的优先实验。但若要形成新工作，必须超过“加时间距离头”：重点检查新地图、方向性、负样本偏差和跨门数据覆盖，并与无动力学检索基线公平对照。

11. World Model Control by Trajectory Reachability Metrics (2026, arXiv v2)。

13 RC-aux: 让训练目标面向有限预算可达性

2026 预印本 • 与 LeWM 直接相关 • 证据: 五个像素控制任务

研究目的

解决单步预测训练与多步规划之间的不匹配: 规划器关心的是剩余动作预算内能否到达, 而不只是下一帧潜变量预测误差。

方法与框架

将多步开环预测损失与预算条件可达性头联合训练: 同一状态对在预算不足时成为时间负样本, 以防模型忽略预算。也用预测潜状态训练该头以贴近规划查询分布。推理时可对被判为可达的候选给予代价折扣, 或关闭该折扣只检验训练端收益。^[12]

实验效果与证据边界

TwoRoom: 续训 LeWM 为 88.8%, RC-aux 为 98.0%; Wall: 原始 LeWM 为 50.4%, RC-aux 为 83.6%。但 PushT 从续训对照的 91.2% 到 90.8%, 并未提高。表中误差条来自五个固定评估组, 不是五个独立训练种子; Wall 也没有同样的续训对照。^[12]

不足与迁移判断

分析: 跨轨迹负样本可能其实能够互达, 轨迹时间代理也继承了行为数据偏差。收益同时涉及多步训练、表示塑形与规划评分, 需要逐项消融, 不能仅凭总体差值判断因果。

对 LeWM 的启示: 与 TRM 形成清晰对照: 冻结世界模型只改目标头, 和允许训练塑造表示, 哪个更能跨地图泛化? 加入纯多步训练、等时长续训、只改规划端三类对照, 能显著提高结论可信度。

12. Predictive but Not Plannable: RC-aux for Latent World Models (2026, arXiv v1)。

14 PiJEPa: 用策略先验改善世界模型搜索

CVPR 2026 Workshop, 非主会 • 证据: CAST 数据上的轨迹误差评估

研究目的

解决从无信息随机动作开始搜索效率低的问题: 世界模型即使能够评价好动作, 搜索器也未必在有限预算内采样到它们。

方法与框架

先微调 Octo 类语言条件策略产生动作分布, 再在共享冻结视觉编码器的 JEPa 潜空间中进行 MPPI。策略负责把候选集中在合理区域, 世界模型负责进一步评估与改进; 论文比较 DINOv2 与 V-JEPa-2 表示。^[13]

实验效果与证据边界

DINOv2 ViT-S 设置下, CAST 验证的 XY 轨迹 RMSE 从 Octo 的 1.98 米降至 PiJEPa 的 1.78 米; 航向 RMSE 从 20.08 降至 19.89, 而普通 MPPI 的 18.79 更低。改进并不覆盖所有指标, 离线误差也不是未知环境长程 SR。^[13]

不足与迁移判断

分析: 收益可能大量来自策略预训练和动作候选本身; 完整策略与世界模型训练成本远高于一个小型目标头。先验如果遗漏必要绕行动作, 局部优化可能仍无法跳出坏路线。

对 LeWM 的启示: 先迁移机制而不是整套大模型: 用轻量行为克隆或轨迹检索生成候选, 再用 LeWM 重排 / 热启动。固定候选数量、执行次数和实际时延, 同时比较“策略单独执行”与“策略 + 世界模型”。

13. Policy-Guided World Model Planning for Language-Conditioned Visual Navigation (2026, CVPR Workshop WDFM-EAI)。

15 HWM：用时间抽象处理长程导航

Hierarchical Planning with Latent World Models • 2026 预印本 • 证据：未知布局迷宫

研究目的

让规划器跳出只顾眼前接近目标的行为，并降低长动作序列搜索和逐步误差累积的难度。高层解决先去哪里，低层解决如何到达。

方法与框架

在冻结低层潜表示之上学习高层世界模型，将原始动作片段编码为宏动作，预测较远的子目标潜状态。高、低两层分别规划，形成时间尺度不同的 MPC。论文将框架用于 PLDM、DINO-WM 和 V-JEPA-2-AC。^[14]

实验效果与证据边界

Diverse Maze 使用 25 个训练布局与 20 个留出布局。最难距离组中，平坦 PLDM 成功率为 44%，分层版本为 83%；中等组为 84% 到 95%，简单组均为 100%。这比操作任务上的成功案例更直接支持导航中的时间抽象。^[14]

不足与迁移判断

分析：输入是俯视 RGB，未见布局不等于“机器人不知道完整地图”；它仍不同于第一人称部分观测探索。高层增加了训练模块和数据需求，宏动作可能不可执行，潜子目标也可能落在训练分布外。

对 LeWM 的启示：先在 LeWM 上比较真实可执行的中间目标、检索子目标和学习宏动作，确认收益来自层级组织。若简单检索已达到相同性能，更复杂高层世界模型的必要性就需要重新论证。

14. Hierarchical Planning with Latent World Models (2026, arXiv v2)。

16 Hi-LeWM: 分层并非一定有效

Mind the Gap • 2026 预印本 v2 • 与 LeWM 直接相关；证据来自操作而非导航

研究目的

检验将层级结构叠加到 LeWM 后是否自然改善长程规划，并分析高层潜空间与底层执行能力之间的落差。

方法与框架

冻结 LeWM，学习预测较长时间变化的高层宏动作模型。研究发现朴素分层可能变差：优化器会利用分布外宏动作产生不切实际的好结果。通过约束经验宏动作分布和调整子目标执行时序，减少无法执行的高层计划。^[15]

实验效果与证据边界

修正后的设置在 PushT 中等和长距离任务上，分别报告 +11.3 和 +14.7 个百分点的成功率提升；论文还研究 OGBench Cube。这些结果是操作任务证据，不能写成“Hi-LeWM 已在未知地图导航中取得同样提升”。^[15]

不足与迁移判断

分析：训练分布约束会限制不合理计划，也可能拒绝真正需要的新路线；改善在多大程度上来自时序参数，而非高层模型，应明确区分。若子目标距离过远，低层的短视评分问题仍可能存在。

对 LeWM 的启示：导航迁移必须加入宏动作可执行性检查：低层能否真实到达高层预测的子目标？先报告子目标落地成功率，再报告整体 SR，才能知道层级是帮助规划还是放大模型误差。

15. Mind the Gap: Promises and Pitfalls of Hierarchical Planning in LeWorldModel (2026, arXiv v2)。

17 CompACT: 少量 token 能否保留控制信息?

Planning in 8 Tokens • CVPR 2026 • 证据: 离线轨迹规划及动力学代理任务

研究目的

缓解大量视觉 token 带来的滚动预测成本，将表示压缩到 8 或 16 个离散 token，同时尽量保留规划相关的物体和空间信息。

方法与框架

冻结 DINOv3，使用可学习查询从稠密特征中汇聚语义，再做有限标量量化。生成式解码器补充可视化细节；动作条件世界模型在紧凑 token 上进行预测。关键是控制所需抽象与完整图像细节分工。^[16]

实验效果与证据边界

同一 RTX 6000 Ada 的轨迹优化比较：SD-VAE 的时延为 178.78 秒，8-token CompACT 为 4.83 秒；但 RECON ATE 从 1.262 变为 1.373，并非精度全面提高。16-token 版本进一步用潜空间代价时为 2.15 秒，ATE 1.379。^[16]

不足与迁移判断

分析：这是显著的效率 / 精度权衡，不是“压缩没有损失”。几秒级轨迹优化也不自动意味着高速机器人可实时安全运行。小门洞、窄通道与相似走廊可能正是压缩表示最容易遗漏的信息。

对 LeWM 的启示：LeWM 本身已经紧凑，不能直接套用针对稠密模型的加速倍数。更值得研究的是单一全局向量与少量空间 token 的区别，检查新增局部空间信息能否改善通道识别和未知布局。

16. Planning in 8 Tokens: A Compact Discrete Tokenizer for Latent World Model (2026, CVPR)。

18 UniWM: 统一动作与视觉生成，并加入记忆

采用 2026 年 arXiv v3; 本文按预印本证据口径 • 主要证据: 离线数据递归评估

研究目的

打破策略产生动作、世界模型预测画面彼此割裂的结构，在统一序列模型中交替生成动作和后续观察，并利用长程记忆保持一致性。

方法与框架

基于多模态自回归模型，组织动作与视觉的交错序列；通过短期 / 跨步 KV 记忆、相似度门控与时间衰减保留有用历史，使预测与动作生成共同使用上下文。^[17]

实验效果与证据边界

论文报告 Go Stanford 上 SR 从对照的 0.45 提高至 0.75。其 SR 定义是预测终点与目标距离小于机器人平均步长；评估依托离线轨迹，并包含模型内部动作 / 视觉递归。因此该 75% 不等同于 Habitat 交互式 ImageNav 的 75%。^[17]

不足与迁移判断

分析：把自己生成的观察继续作为输入，可能强化内部一致但偏离真实环境的故事。统一模型也可能主要靠行为模仿生成动作；若不消融未来视觉分支，就无法证明提升由世界建模带来。

对 LeWM 的启示：先借鉴记忆选择和跨步信息管理，不必替换 LeWM 全架构。应做真实环境回馈与预测图像回馈的分别评估，检查一旦偏离数据轨迹，系统能否利用新观察恢复。

17. Towards Unified World Models for Visual Navigation via Memory-Augmented Planning and Foresight (2026, arXiv v3)。

19 近期扩展：空间感知与统一生成

NavWM / SWAM 按预印本处理；下面的数值不构成共同排行榜。

NavWM：前瞻驱动的统一导航模型

目的与方法：用统一模型联合动作预测与未来视觉生成，结合状态空间序列建模、空间监督及轨迹候选信息。效果：论文离线四数据集平均 ATE 为 0.207、RPE 为 0.066，同表 UniWM 为 0.302、0.116。这里是离线动作与视觉评价，不是仿真闭环 SR。^[18]

不足与启示（分析）：空间教师、候选先验和生成模块共同变化，不能只归因于世界模型。迁移到 LeWM 时，最有价值的是验证空间辅助监督是否改善动作排序，而不是照搬统一大模型。

SWAM：联合空间感知、未来世界与动作

目的与方法：将 RGB、深度与动作联系起来，以深度教师和空间一致性设计增强导航生成。效果：RECON / SCAND / TartanDrive 的 ATE 为 0.93 / 1.15 / 1.55，同表 NWM+NoMaD (16 候选) 为 1.53 / 2.18 / 6.23；所报生成用时为 16.91 秒 / 样本。^[19]

不足与启示（分析）：显著改善的是轨迹误差；16.91 秒也不等于机器人实时决策。需要区分“一次联合生成”与内部多次去噪。更适合给 LeWM 增加几何一致性监督，而非直接承担低层控制。

两者与 LeWM 的关系

这条路线希望把“看清空间”“预测未来”和“生成动作”融合为一个系统，优势是共享信息，代价是更难分离每一项能力的来源。对轻量 LeWM 而言，优先迁移可独立验证的空间监督或动作一致性机制；仅复制生成分支，未必能修复隔墙目标度量和长程搜索问题。

18. NavWM: A Unified Navigation World Model for Foresight-Driven Planning (2026, arXiv v1)。

19. Pondering the Way: Spatial-perceiving World Action Model for Embodied Navigation (2026, arXiv v1)。

20 GeniNav: 语义想象与几何可行性结合

CVPR 2026 • 证据: GeniBench 闭环、跨数据集评估及真实机器人

研究目的

让图像目标导航同时具备高层语义引导、平滑运动与显式轨迹评价，并提供可交互的闭环基准，弥补仅用离线轨迹误差评价导航的不足。

方法与框架

由 VLM 想象潜在子目标，再用多段一致性流匹配生成动作；混合评价模块同时考虑语义与几何。GeniBench 覆盖 176 场景、491.6 千米，成功要求执行停止、距目标 1 米内且朝向偏差不超过 25 度。^[20]

实验效果与证据边界

所有方法在 Gibson 训练，留出 Gibson 场景上 GeniNav 的 SR / SPL / 碰撞回合率为 68.7 / 59.4 / 9.8%，同表 MetricNet 为 54.5 / 43.3 / 11.9%；不微调迁移至 MP3D 后为 55.2 / 45.7 / 14.2%。注意实机部署另有小规模真实数据微调，不是完全零样本实机迁移。^[20]

不足与迁移判断

分析：该系统更接近想象辅助生成策略，不能简单视作 LeWM 同型动力学。基线被调整为无预建地图、部分传感器由 LiDAR 改为深度，其排名应限定于该改造协议；碰撞率也仍非零。

对 LeWM 的启示：优先借鉴严格停止 / 朝向条件、碰撞指标和语义几何混合评分。在迁移实验中，分别比较局部可行性评分、子目标想象与 LeWM 预测的增益，避免把完整系统优势全部归于世界模型。

20. GeniNav: Generative Model Driven Image-Goal Navigation via Imagination-Guided Consistency Flow Matching (2026, CVPR)。

21 MCR：直接训练候选动作的代价排序

2026 年 8 月预印本 v1 • 证据：GNM 离线轨迹与小规模实机

研究目的

让世界模型不仅预测接近真实的未来，还能给不同动作排出有用的优劣顺序。它与 TRM 的问题动机接近，但不另接一个时间距离头，而是塑造预测器所产生的规划代价。

方法与框架

冻结 DINO 编码器，以动作调制 Transformer 自回归预测；先用多步滚动损失训练，再做 Monotone Cost Ranking。对参考动作加入不同扰动，按运动积分后的轨迹偏差排序，要求偏差较大的候选具有更高的目标特征代价，同时保留原轨迹预测损失。^[21]

实验效果与证据边界

同一 DINOv2 编码器下，Base 到 MCR 的平均朝向误差由 9.12 度降至 7.63 度，ADE 由 1.12 米降至 0.99 米；但 NoMaD 的 ADE 为 0.88 米，更低。实机只报告五个代表性场景中 5/5 成功，对照 2/5，不能视为大规模可靠性验证。^[21]

不足与迁移判断

分析：偏离参考轨迹不一定更差，另一条绕障路线也可能可行；运动积分本身不检查障碍。实机使用 LiDAR 与 Nav2 完成低层规划、避障和不可达路点回退，因此不能把安全性全部归于潜世界模型。

对 LeWM 的启示：把 MCR 作为 RC-aux 的候选级对照：监督动作排序是否比状态对时间距离更适合新地图？应保留多条有效路线，避免把合理绕行当作负样本；单独比较多步训练与排序损失的贡献。

21. Latent World Models with Monotone Planning Costs for Image-Goal Navigation (2026, arXiv v1)。

22 NavWAM: 让世界模型直接输出动作

2026 年 6 月预印本 v1 • 证据: 离线评估与 24 回合实机闭环

研究目的

减少“先生成候选，再逐条预测、评分和搜索”的推理负担，将未来预测、目标进展和动作生成共同训练，让世界模型成为直接执行的导航策略。

方法与框架

采用约 20 亿参数的 Cosmos Predict2 视频骨干，将目标图像、当前状态、动作块、未来观察与进展值组织成共享潜序列，联合去噪。先做仿真预训练，再适配真实机器人数据；默认策略模式直接生成动作块，不使用 CEM 搜索。^[22]

实验效果与证据边界

Diablo 机器人四个室内环境共 24 回合：NavWAM 成功 19/24，即 79.2%；OmniVLA 为 14/24，NWM 为 4/24。论文给出 NavWAM 的 95% Wilson 区间为 59.5%–90.8%。Go Stanford 离线 ATE 为 0.324，数据集内微调后为 0.192。^[22]

不足与迁移判断

分析：24 回合的区间仍较宽，不能据此确认普遍优势。大规模预训练、动作监督及进展值同时参与，结果不等于未来图像预测的独立收益；直接生成动作也可能继承行为数据中的路线偏差。

对 LeWM 的启示：不必迁移整套视频模型。可以在 LeWM 表示上增加轻量动作提议与进展预测，比较纯策略、纯模型规划及联合方式。核心问题是联合训练能否改善真实执行，而不仅是让多个输出看起来一致。

22. NavWAM: A Navigation World Action Model for Goal-Conditioned Visual Navigation (2026, arXiv v1)。

23 面向 LeWM 的研究方向排序

以下是研究优先级判断，不是已经获得的实验结论。目标是在有限改动下辨认真正瓶颈，再逐步增加模型复杂度。

优先级	研究问题	对应工作	关键成败标准
第一优先	可达性与目标代价	TRM、RC-aux、MCR	排除轨迹重叠后，能否跨布局；是否优于无动力学检索
第一优先	可信宏动作与长程规划	HWM、Hi-LeWM	子目标可执行；长程提升不是增加搜索预算造成
第二优先	部分观测中的历史记忆	NavMorph、SC2-WM、UniWM	回访、相似走廊和遮挡下提升；不依赖全局地图
第二优先	策略候选与预测反馈	NWM、PiJEPa	世界模型重排优于候选直接执行；能识别错误预测
条件推进	结构化表示与空间监督	DINO-WM、RAE-NWM、CompACT	等预算改善门洞 / 朝向 / 障碍辨识，而非只换更强编码器
后续扩展	语言 / 物体目标	UNeMo、WMNav、GeniNav	语义目标被落实为真实可达子目标，而非语言幻觉

最有研究价值的交叉点

“地图与预算条件的可达性 + 可执行子目标 + 记忆”具有较清晰的问题动机：TRM / RC-aux 处理目标度量，HWM 处理远期规划，NavMorph / SC2-WM 处理历史与反馈。但三者的组合目前不能被上述论文结果直接保证。^{[7][9][11][12][14]}

建议将创新问题表述为：在局部观测和未见拓扑下，如何让轻量潜世界模型建立可校准的可达关系，并选择低层能够实现的子目标？相比“给 LeWM 加某模块”，这种表述更容易定义可证伪假设、建立必要基线并形成有说服力的科研贡献。

7. NavMorph: A Self-Evolving World Model for Vision-and-Language Navigation in Continuous Environments (2025, ICCV)。
9. SC2-WM: A Self-Correcting World Model with Closed-Loop Feedback for Vision-and-Language Navigation in Continuous Environments (2026, ICML)。
11. World Model Control by Trajectory Reachability Metrics (2026, arXiv v2)。
12. Predictive but Not Plannable: RC-aux for Latent World Models (2026, arXiv v1)。
14. Hierarchical Planning with Latent World Models (2026, arXiv v2)。

24 能够支持研究结论的实验设计

本节是建议的研究方案，不表示这些实验已经运行或已得到结果。

严格划分，而不只是换一个随机数

依次区分：同地图新轨迹、同拓扑新门位置、新拓扑布局、新外观与第一人称部分观测。训练 / 验证 / 测试必须按完整轨迹和地图组织；目标对、检索库、时间距离头、归一化参数均不能使用测试轨迹。地图结构用于指标计算时，必须与模型可见信息隔离。

分离四个可能的瓶颈

诊断对照	回答的问题
原始 LeWM vs. 冻结 LeWM + 目标头	是不是目标度量不适合绕行？
同一候选集：模型排序 vs. 真值排序	评分是否正确；候选里本来有没有好解？
策略 / 检索单独执行 vs. 加 LeWM 重排	收益来自候选，还是来自预测？
真实中间目标 vs. 检索目标 vs. 学习目标	高层目标是否可执行？
单帧 vs. 多帧 vs. 记忆；其余固定	失败是否由部分观测导致？
原模型续训 vs. 多步训练 vs. RC-aux	额外计算、预测跨度与可达性损失各贡献多少？

等预算与不确定性

同时报告训练数据量、训练时长、模型调用量、实际决策时延与 SR / SPL；等候选数不一定等算力。至少使用多个独立训练种子；固定评估回合、地图分层汇总并报告配对差值或置信区间。不能把同一模型多次评估冒充多种子训练。

失败分类比一张平均分表更重要

建议记录：错房间、卡墙、穿门失败、绕行过长、循环回访、到达却不停止、朝向错误，以及预测终点很好但真实执行很差。额外保存短视频、候选排名、真实终点和子目标完成率；这些信息决定下一步应该改表示、规划、记忆还是反馈。

25 总结：哪些结论成立，哪些仍未解决

已有较强证据支持的判断

潜空间建模能降低像素生成的计算开销，但压缩程度与控制信息保留存在权衡；目标代价和动作搜索本身可以成为主要瓶颈。DINO-WM、NWM、CompACT 分别从表示、未来模拟与计算效率提供证据。^{[3][4][16]}

针对长程导航，时间抽象有直接的未知布局迷宫证据；但层级结构也会产生不可执行子目标。HWM 与 Hi-LeWM 应成对阅读，前者说明潜力，后者提醒迁移不能省略可执行性诊断。^{[14][15]}

语言导航中的记忆和反馈方法在连续环境获得了 SR / SPL 改善，但这是完整系统的能力。将这些机制迁移到轻量 LeWM 时，需要重新确认额外输入与预训练资源的作用。^{[7][9]}

尚不能据此宣称解决的问题

离线轨迹准确不等于未知环境闭环可靠；好看的长视频不等于正确的反事实动力学；同地图高成功率不等于新拓扑泛化；小规模实机演示不等于安全部署。论文使用的“world model”也并不统一，语义价值地图、视频生成器和动作条件潜动力学需要分别讨论。

建议的阅读与实现顺序

第一轮精读 LeWM、PLDM、TRM、RC-aux，确定问题和目标度量；第二轮阅读 HWM 与 Hi-LeWM，设计长程可执行子目标；第三轮阅读 NavMorph、SC2-WM 与 WMNav，进入部分观测和探索；最后根据失败来源选择 PiJEPA、RAE-NWM 或 CompACT 的结构。

最重要的研究原则是：只有在控制数据、信息、候选与计算预算后仍然存在的改进，才足以支持“世界模型带来了新的导航能力”这一结论。

3. DINO-WM: World Models on Pre-trained Visual Features Enable Zero-shot Planning (2025, ICML)。

4. Navigation World Models (2025, CVPR)。

7. NavMorph: A Self-Evolving World Model for Vision-and-Language Navigation in Continuous Environments (2025, ICCV)。

9. SC2-WM: A Self-Correcting World Model with Closed-Loop Feedback for Vision-and-Language Navigation in Continuous Environments (2026, ICML)。

14. Hierarchical Planning with Latent World Models (2026, arXiv v2)。

15. Mind the Gap: Promises and Pitfalls of Hierarchical Planning in LeWorldModel (2026, arXiv v2)。

16. Planning in 8 Tokens: A Compact Discrete Tokenizer for Latent World Model (2026, CVPR)。

参考文献与原始来源

所有编号均可点击打开原始论文；版本、表格和成功阈值以各节说明为准。

[1] Lucas Maes et al.. LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels. 2026, arXiv v3.

<https://arxiv.org/html/2603.19312v3>

[2] Vlad Sobal et al.. Learning from Reward-Free Offline Data: A Case for Planning with Latent Dynamics Models. 2025, NeurIPS; arXiv v4.

<https://arxiv.org/html/2502.14819v4>

[3] Gaoyue Zhou et al.. DINO-WM: World Models on Pre-trained Visual Features Enable Zero-shot Planning. 2025, ICML.

<https://arxiv.org/html/2411.04983>

[4] Amir Bar et al.. Navigation World Models. 2025, CVPR.

<https://arxiv.org/html/2412.03572>

[5] Mingkun Zhang et al.. RAE-NWM: Navigation World Model in Dense Visual Representation Space. 2026, arXiv v2.

<https://arxiv.org/html/2603.09241v2>

[6] Zhiwei Zhang et al.. Efficient Image-Goal Navigation with Representative Latent World Model. 2025, arXiv v2.

<https://arxiv.org/html/2511.11011v2>

[7] Xuan Yao, Junyu Gao, Changsheng Xu. NavMorph: A Self-Evolving World Model for Vision-and-Language Navigation in Continuous Environments. 2025, ICCV.

<https://arxiv.org/html/2506.23468>

[8] Changxin Huang et al.. UNeMo: Collaborative Visual-Language Reasoning and Navigation via a Multimodal World Model. 2026, AAAI; arXiv v2.

<https://arxiv.org/html/2511.18845v2>

参考文献与原始来源（续）

所有编号均可点击打开原始论文；版本、表格和成功阈值以各节说明为准。

[9] Xuan Yao et al.. SC2-WM: A Self-Correcting World Model with Closed-Loop Feedback for Vision-and-Language Navigation in Continuous Environments. 2026, ICML.

<https://arxiv.org/html/2608.07548>

[10] Dujun Nie et al.. WMNav: Integrating Vision-Language Models into World Models for Object Goal Navigation. 2025, IROS.

<https://arxiv.org/html/2503.02247>

[11] Liangyu Li et al.. World Model Control by Trajectory Reachability Metrics. 2026, arXiv v2.

<https://arxiv.org/html/2605.22164v2>

[12] Wenyuan Li et al.. Predictive but Not Plannable: RC-aux for Latent World Models. 2026, arXiv v1.

<https://arxiv.org/html/2605.07278v1>

[13] Amirhosein Chahe, Lifeng Zhou. Policy-Guided World Model Planning for Language-Conditioned Visual Navigation. 2026, CVPR Workshop WDFM-EAI.

<https://arxiv.org/html/2603.25981>

[14] Wancong Zhang et al.. Hierarchical Planning with Latent World Models. 2026, arXiv v2.

<https://arxiv.org/html/2604.03208v2>

[15] Niccolo Caselli et al.. Mind the Gap: Promises and Pitfalls of Hierarchical Planning in LeWorldModel. 2026, arXiv v2.

<https://arxiv.org/html/2607.12547v2>

[16] Dongwon Kim et al.. Planning in 8 Tokens: A Compact Discrete Tokenizer for Latent World Model. 2026, CVPR.

<https://arxiv.org/html/2603.05438>

参考文献与原始来源（续）

所有编号均可点击打开原始论文；版本、表格和成功阈值以各节说明为准。

[17] Yifei Dong et al.. Towards Unified World Models for Visual Navigation via Memory-Augmented Planning and Foresight. 2026, arXiv v3.

<https://arxiv.org/html/2510.08713v3>

[18] Yanghong Mei et al.. NavWM: A Unified Navigation World Model for Foresight-Driven Planning. 2026, arXiv v1.

<https://arxiv.org/html/2606.24101v1>

[19] Hong Chen et al.. Pondering the Way: Spatial-perceiving World Action Model for Embodied Navigation. 2026, arXiv v1.

<https://arxiv.org/html/2606.29908v1>

[20] Yuqi Chen et al.. GeniNav: Generative Model Driven Image-Goal Navigation via Imagination-Guided Consistency Flow Matching. 2026, CVPR.

https://openaccess.thecvf.com/content/CVPR2026/papers/Chen_GeniNav_Generative_Model_Driven_Image-Goal_Navigation_via_Imagination-Guided_Consistency_Flow_CVPR_2026_paper.pdf

[21] Amirhosein Chahe, Siwei Cai, Lifeng Zhou. Latent World Models with Monotone Planning Costs for Image-Goal Navigation. 2026, arXiv v1.

<https://arxiv.org/html/2608.09073v1>

[22] Daichi Azuma et al.. NavWAM: A Navigation World Action Model for Goal-Conditioned Visual Navigation. 2026, arXiv v1.

<https://arxiv.org/html/2606.13494v1>

发表信息与补充来源

PLDM / NeurIPS 2025

DINO-WM / ICML 2025

NWM / CVPR 2025

NavMorph / ICCV 2025

UNeMo / AAAI 2026

SC2-WM / ICML 2026 官方日程

WMNav / IROS 2025

PiJEPA / CVPR 2026 Workshop

CompACT / CVPR 2026

RAE-NWM 作者仓库: provisionally accepted

GeniNav / CVPR 2026 论文

版本与状态说明

资料截止 2026 年 9 月 10 日。RAE-NWM 的作者仓库使用“暂定接收”措辞，因此本文不将其写为已经完成正式出版。对其他未确认正式发表的最新工作，也不推断投稿状态。

GeniNav 的方法还可参阅其官方项目页 <https://cyq638.github.io/geninav/>。所有工作所列性能均来自对应原始论文的指定实验；不把不同成功阈值、输入配置或控制预算下的数字合并排名。