Image-target 导航
数据体系与相关模型调研

JEPA-VLN 的视觉理解、目标定位与机器人路线生成

资料核查日期：2026年10月14日

1. 任务定义与数据选择

研究任务以目标图像为输入，不要求天然存在语言指令。纯图像目标任务更准确的名称是 ImageGoal Navigation；加入语言补充、目标描述或指令后才进入相应的视觉语言导航设置。下面两种任务独立评测，不混用成功判定。

任务	目标含义	关键能力
地点图像导航	到达目标照片的拍摄位置；朝向一致性另列严格指标。	跨视角地点识别、未知区域探索、最后一米定位。
物体实例图像导航	找到目标照片中的同一个物体，不是任意同类物体；不要求回到拍摄点。	类别理解、实例重识别、主动靠近确认、可见且可到达的停靠位置。

场景采用 Gibson Habitat 版本与 HSSD 的原始刚体场景；不依赖 HM3D / Matterport 账号。Gibson 提供真实室内扫描，HSSD 提供由人工布置的室内合成场景及独立物体资产。HSSD 原论文介绍211个场景和18,656种物体模型；当前公开仓库不同版本的可用场景数量并不相同，最终规模以实际下载、加载和质量验收统计为准。

Gibson 官方场景包是场景资源，不等于导航回合或训练轨迹。现成的 ImageGoal 回合优先保留原始评测划分；HSSD 的物体实例任务为本项目派生任务，不称为官方 HM3D InstanceImageNav。

Gibson ImageGoal 原始回合 / HSSD 场景与许可 / HSSD 方法与数据说明

2. 数据构建与验收规范

先按完整场景划分训练、验证与测试，再生成图像与轨迹。HSSD 保留作者验证场景，从作者训练场景中固定留出一组本地测试场景；本地测试和作者正式评测结果分开报告。调试场景不计入正式训练或测试规模。

数据层	保存内容	用途
场景与来源	固定版本、下载来源、许可、校验结果、场景依赖。	可重现地加载与追踪资源。
目标与回合	起点、朝向、目标图像、拍摄参数、路径距离、实例ID。	ImageGoal 与 InstanceImageGoal 独立任务包。
物体多视角	同一实例多张图、实例掩码、可见停靠点、同类干扰物。	训练对应关系、验证找错实例的失败。
时序轨迹	第一视角图像、动作命令、实际位移、朝向变化、碰撞。	训练动作条件预测与导航策略；训练场景限定。

目标照片必须能正常渲染。起终点必须位于可通行区域，并有有限的实际绕障路径；HSSD 的可通行区域重新计算时包含静态家具。物体目标必须有足够可见像素、至少两个有效视角和可达的接近位置。被遮挡、无法接近或未加载完整的物体不计为有效样本。

生成数据不是模型成绩：专家路线使用导航网格和真值位置，只用于标签和采集。模型默认只接收当前与历史 RGB、目标图像和历史动作；深度作为独立输入设置。坐标、实例ID、目标掩码及全局地图均不作为默认策略输入。

分类评测覆盖：短 / 中 / 长距离、直达 / 需要绕行、目标与观测视角差异、同类干扰物、多房间及未见场景。严格的纹理、照明、相机高度和视场角变化属于后续独立扰动集，不能在尚未实现时宣称已覆盖。

3. 指标与比较原则

指标	解释	注意事项
SR	明确 STOP 后是否到达正确目标。	地点距离阈值和实例可见停靠集合分开定义。
SPL / SoftSPL	到达效果与路径效率；SoftSPL补充未成功样本的进展。	起始最短路径与真实行走距离保持同一几何定义。
错误实例停止率	在同类但不同实例旁停止的比例。	将感知混淆与单纯未到达区分开。
碰撞 / 超时 / 延迟	执行安全、循环停滞和决策开销。	固定动作预算；实测推理延迟，不仅统计规划次数。
严格位姿指标	更小的位置误差和朝向误差。	作为补充，不替换原始宽松成功指标。

对比矩阵固定场景划分、传感器、动作接口、预算和停靠判定。RGB策略、RGB-D模块化系统、带里程计系统分组比较；不能把额外真值地图或目标坐标输入的结果列为同等条件。

图像理解模型的分割AP或几何重建精度，不等于导航成功率；机器人路线模型的轨迹误差，也不等于未知场景闭环到达率。下面对模型的迁移限制是针对本任务的分析，而非声称每篇论文都直接测试过这些失败。

优先基线：地点任务采用 DEBiT、FGPrompt；物体实例任务采用模块化匹配 / 探索基线及 IEVE 的确认逻辑；路线生成采用 ViNT / NoMaD、NavDP。模型输入不符合本项目设置时，先给出适配和控制变量说明，不直接照搬作者结果。

4. 目标图像理解：局部特征与分割

1. DINOv3 | 2025 技术报告

研究方向：用于目标照片和当前视图的密集特征提取，支持局部匹配和实例检索。

架构：教师-学生自监督视觉编码器；ViT 输出全局与 patch 特征，后续蒸馏为多个模型规模。

创新点：Gram anchoring约束patch间关系，缓解长时间大规模训练中的密集特征退化。

证据与局限：论文展示分割、深度和3D匹配等任务的强特征。 它不是导航策略；相似家具仍可能得到相近特征，必须结合几何、上下文和时序确认。

论文与方法来源 / 代码与实现

2. SAM 3 | 2025 技术报告

研究方向：理解“图中有哪些目标候选”，生成目标掩码并跟踪已观察对象。

架构：共享视觉语言骨干；图像检测器与带记忆的视频跟踪器分工，接收文本、示例图或交互提示。

创新点：把概念是否存在与目标定位分离；以概念提示分割同概念的多个实例。

证据与局限：作者报告开放词汇分割与视频跟踪提升。 同一概念下的多个物体仍需区分；示例提示不自动等价于跨房间、跨视角的唯一物理实例重识别。

论文与方法来源 / 代码与实现

5. 目标图像理解：几何与动态表征

3. VGGT | CVPR 2025

研究方向：从多视图恢复相机和场景几何，为目标定位提供空间约束。

架构：DINO图像patch与相机token进入交替单帧 / 全局注意力；相机、深度、点图和跟踪特征由多头输出。

创新点：将多个几何任务放到一次前向预测中，减少传统两两匹配与后端优化的依赖。

证据与局限：论文验证多种几何任务。 计算与显存随视图增长；尺度和难视角误差仍影响实际停靠。它重建已见场景，不自动预测动作结果。

论文与方法来源 / 代码与实现

4. JEPA-VLA | 2026 论文

研究方向：以视频预测表征补充VLA的状态理解与动作先验，是本方向的表征融合参考。

架构：V-JEPA 2预测表征与原VLA视觉表征采用early fusion或gated fusion，再由原模型动作模块执行。

创新点：不是简单替换视觉骨干，而是利用视频表征与图文表征的互补性。

证据与局限：作者在LIBERO、RoboTwin及真机操控任务验证改进。 操控证据不等于导航能力；需新增图像目标对齐、空间记忆、导航动作与闭环到达评测。

论文与方法来源

6. 图像目标导航：直接对应关系

5. DEBiT | ICLR 2024

研究方向：同时处理地点图像与实例图像目标，学习当前视图和目标之间的对应。

架构：双目ViT联合处理观测和目标；几何相关预训练后接记忆与强化学习导航模块。

创新点：将对应关系学习融入端到端导航，而不是只比较两个独立全局向量。

证据与局限：原论文与官方仓库提供导航评测和多个模型权重。 部分预训练数据未公开；迁移到不同传感器、场景和实例停靠协议时必须单独校准。

论文与方法来源 / 代码与实现

6. FGPrompt | NeurIPS 2023

研究方向：以目标图像中的细节引导当前观测编码。

架构：目标高分辨率特征作为提示，通过早期或中间融合进入观测特征，再由循环导航策略输出动作。

创新点：保留细粒度目标信息，减少全局压缩后无法区分细节的问题。

证据与局限：官方公布Gibson评测权重与结果。 主要为地点图像导航；到达目标拍摄位置，不自动解决同类不同物体的身份验证。

论文与方法来源 / 代码与实现

7. 实例目标导航：主动确认与图结构

7. IEVE | CVPR 2024

研究方向：在陌生环境中找目标照片里的同一实例。

架构：类别识别与RGB-D语义建图后，由切换策略选择探索、靠近验证或利用；局部策略执行。

创新点：“靠近再确认”是连续决策，而不是远处做一次相似度判断；匹配阈值与目标距离关联。

证据与局限：论文HM3D-SEM设置中报告SR从对照0.561提升至0.684 / 0.702。 这些值不是本项目HSSD成绩；分割、深度与位姿依赖需明确，手工切换规则也可能在新分布失效。

论文与方法来源 / 代码与实现

8. UniGoal | CVPR 2025

研究方向：把类别、图像和文本目标统一为可匹配的目标图。

架构：目标图与在线场景图匹配；从粗匹配转向更完整匹配，结合VLM / LLM修正与验证，再做局部导航。

创新点：用目标周边关系帮助寻找与确认，并记录失败候选避免重复尝试。

证据与局限：作者在多个目标形式上验证零样本导航。 图结构和语言推理误差会累积；实例任务仍需局部对应验证，调用成本也高于轻量策略。

论文与方法来源

8. 地点图像导航：定位与最后一米

9. IGL-Nav | ICCV 2025

研究方向：把目标照片定位到已探索的三维空间。

架构：在线增量3D高斯场景表示；粗阶段几何离散匹配，近目标后以可微渲染优化拍摄位姿。

创新点：可渲染空间记忆把目标图像与几何联系起来，支持自由视角目标。

证据与局限：作者在多种图像目标设置和真机平台验证。 三维表示与定位开销、重建漂移仍需管理；无重叠目标视图时仍离不开探索。

论文与方法来源 / 代码与实现

10. AnyImageNav | 2026 预印本

研究方向：解决传统1米成功阈值掩盖的精确停靠问题。

架构：把任意视角目标作为几何查询；密集像素对应恢复目标相机位姿，再执行接近与对齐。

创新点：将最终位置与朝向从粗到达任务中显式拆出，适合后续近距离操作。

证据与局限：作者展示任意目标照片的最后一米导航。 像素重叠不足、遮挡与弱纹理限制配准；精确拍摄位姿仍不同于物体实例的可见停靠集合。

论文与方法来源

9. 机器人路线生成：基础模型与扩散

11. ViNT | CoRL 2023

研究方向：从观测历史与目标照片生成跨机器人可执行的局部路线。

架构：图像编码器与Transformer融合历史和目标，预测局部waypoints及到达距离；可结合拓扑记忆。

创新点：用跨平台导航数据预训练，把局部视觉运动能力迁移到新机器人。

证据与局限：官方提供模型、数据处理和ROS部署流程。 公开部署常配合预先采集的拓扑路线；不能将路线跟随成绩理解为完全未知场景探索。

论文与方法来源 / 代码与实现

12. NoMaD | 2023-2024 工作

研究方向：统一有目标导航和无目标探索，并生成多种合理路线。

架构：目标mask控制视觉Transformer条件；扩散动作头采样局部路线，控制器执行短段。

创新点：有目标和目标被遮住的训练共享策略，扩散减少单一回归路线的多模态平均问题。

证据与局限：官方提供真机导航与探索示例及预训练权重。 无目标路线生成不等于能高效找到特定实例；还需长程记忆和明确的目标验证机制。

论文与方法来源 / 代码与实现

10. 机器人路线生成：仿真与交互适配

13. NavDP | ICRA 2026

研究方向：以仿真轨迹训练可跨机器人迁移的局部导航策略。

架构：RGB-D和目标token由共享Transformer融合；扩散头生成候选轨迹，critic对安全性评分并筛选。

创新点：在训练期利用全局规划与ESDF特权信息，同时提供正路线和负路线反馈。

证据与局限：论文训练集覆盖1244个场景、363.2km轨迹，并验证多种真机。 依赖深度及局部观测；训练规模不是本项目规模，不能据此宣称解决长程探索与实例身份。

论文与方法来源 / 代码与实现

14. X-NavDP | CoRL 2026（作者公告）

研究方向：通过交互后训练，使已有扩散路线策略适应新行为和机器人。

架构：在NavDP基础上结合轨迹扰动、机器人条件调制和组内Q分数重加权，优化扩散训练目标。

创新点：从只模仿已有路线转向反馈驱动的策略改进，减少对单一示范分布的限制。

证据与局限：作者提供后训练和跨具身实验。 公开仓库标注的基线支持PointNav；应作为动作适配参考，不能直接算作同等条件的图像目标基线。

论文与方法来源 / 代码与实现

11. 图像路线模型与双系统导航

15. PIG-Nav | 2025 预印本

研究方向：预训练当前图像到目标图像的路线生成器。

架构：两张图的patch早期融合到ViT；waypoint主任务联合相对位姿、导航距离和全局路线辅助头。

创新点：数据兼用机器人与游戏视频，辅以导航相关监督而非只监督短动作。

证据与局限：作者在Highrise和Sanctuary验证零样本及微调提升。 游戏与真实室内扫描存在域差异；地点图像目标不等于物体身份目标，公开权重需重新闭环验证。

论文与方法来源 / 代码与实现

16. DualVLN / InternVLA-N1 | 2025-2026 工作

研究方向：把较慢的语义目标解释和较快的局部路线执行分开。

架构：高层VLM输出空间接地 / 潜在计划；低层轨迹模型据局部观测执行，高层低频更新。

创新点：中间计划连接语义推理与连续运动，避免每一步都完整运行大模型。

证据与局限：作者提供语言导航和物理仿真 / 部署体系。 主要输入是语言指令；用于本项目时需替换目标接地接口，并单独检验照片中的实例身份。

论文与方法来源 / 代码与实现

12. 动作执行与场景记忆扩展

17. NaVILA | RSS 2025

研究方向：将视觉语言导航意图转为腿式机器人运动。

架构：高层视觉语言模型产生语言化动作指令，低层视觉运动强化学习控制器执行。

创新点：明确分离任务推理和身体控制，支持复杂真实环境运动。

证据与局限：作者展示腿式机器人真实导航。 不是纯图像目标系统；应参考意图到控制的接口，不能把低层运动能力直接视为目标搜索能力。

论文与方法来源 / 代码与实现

18. Unordered Landmark Visual Navigation | 2026年8月预印本

研究方向：利用无时间顺序的地标图像定位和规划，扩展图像目标的记忆设置。

架构：将地标组织为拓扑结构，通过图上的信念更新处理定位，再连接导航决策。

创新点：不要求目标图像按一条既定路线排序，为稀疏图像记忆提供另一种组织方式。

证据与局限：论文讨论无序地标导航设置。 多张预先提供的地标是额外信息，不能与只给一张目标图且未知地图的设置直接比较。

论文与方法来源

13. 世界模型：生成未来与预测潜变量

19. Navigation World Models (NWM) | CVPR 2025

研究方向：给候选导航动作预测未来第一视角画面。

架构：动作条件视频生成骨干预测未来观测，外部规划器采样动作序列并比较目标进展。

创新点：将视觉未来显式纳入导航选择，而不是只从当前图像回归动作。

证据与局限：作者验证可控未来生成与导航用途。 视频生成质量不等于安全或可达性；长程误差与候选搜索计算量会影响闭环表现。

论文与方法来源 / 代码与实现

20. PiJEPA | 2026 论文

研究方向：用策略先验缩小潜空间规划的搜索范围。

架构：Octo给动作先验；DINOv2或V-JEPA 2表征及动作条件预测器作rollout；MPPI细化候选动作。

创新点：世界模型不从无信息动作分布开始搜索，而是改进已有较合理的策略提案。

证据与局限：CAST验证中V-JEPA 2版本ATE位置RMSE为1.65m，对照Octo为1.72m。 主要证据是轨迹误差，而非大规模未知室内闭环SR；纯世界模型筛选已贡献不少提升，需分离筛选与优化收益。

论文与方法来源

14. 世界-动作模型：联合预测

21. NavWAM | 2026年6月预印本

研究方向：联合生成导航动作、未来视觉及目标进展。

架构：基于Cosmos Predict2的VAE与DiT，将图像、动作、状态和值放入共享latent canvas进行去噪。

创新点：未来画面和可执行动作一起学习，默认以预测动作块滚动执行，而非必须额外运行CEM。

证据与局限：作者给出图像目标导航实验。 较大视频模型与联合去噪仍有推理成本；目前图像目标设置不自动支持唯一物体实例或任意语言。

论文与方法来源

22. WAM-Nav | 2026年6月预印本

研究方向：在同一模型内兼顾局部动作和视觉前瞻。

架构：非对称潜空间世界-动作建模，对较长动作序列和较短视觉未来联合建模，融入自运动与视觉上下文。

创新点：避免视觉和动作使用完全相同预测长度，围绕导航实际执行需求配置预测预算。

证据与局限：作者报告统一视觉导航实验。 本项目仍须验证长程记忆、错误实例拒绝与停靠；预印本的作者结果不是本地复现结果。

论文与方法来源

15. 模块选择与研究路线

模块	优先参考	在本项目中的位置
目标理解与匹配	DINOv3、SAM 3、VGGT	保留目标patch、实例掩码及几何线索；不只用一个类别向量。
定位与主动确认	DEBiT、IEVE、UniGoal、IGL-Nav	跨视角对齐，积累证据，拒绝错误实例，决定是否靠近确认。
局部路线与执行	ViNT / NoMaD、NavDP、PIG-Nav	预测局部路线；统一坐标系、动作尺度、碰撞与控制周期。
时序预测	JEPA-VLA、PiJEPA、NWM / NavWAM	融合动态表征；比较动作条件潜预测与像素未来的收益和开销。

第一步：完成场景、任务回合和图像验收，冻结场景划分。地点与物体实例分别报告规模、失败原因及样例，调试数据不能列为正式大规模数据。

第二步：固定感知和控制条件，运行地点匹配基线、实例确认基线和局部路线基线。分离找不到目标、找错实例、已定位但路线失败、停靠失败四种错误。

第三步：采用JEPA-VLA式表征融合，先冻结视频骨干；目标图像保留局部特征，以历史观测和历史动作建立因果记忆。先检验表征融合，不同时改动所有组件。

第四步：加入动作条件潜变量预测，为候选路线预测目标进展或可见性。将“原策略”“世界模型筛选”“规划细化”在等时间预算下比较，同时报告碰撞与错误实例停止率。

第五步：在未见场景、较大视角差、同类干扰和绕行路线中检验收益；再加入相机变化与真实运动接口。导航位置 / 局部waypoints到机器人控制的接口，与机械臂操作能力分别验证。

核心检验不是“用了JEPA是否更先进”，而是动态表征是否在相同数据和执行预算下改善了正确目标确认、动作后果判断及未知场景闭环到达。